

Санкт–Петербургский государственный университет

КРАСНИКОВ Алексей Алексеевич

Выпускная квалификационная работа

***Обнаружение мошеннических финансовых транзакций
с использованием методов машинного обучения***

Уровень образования: бакалавриат

Направление 01.03.02 «Прикладная математика и информатика»

Основная образовательная программа СВ.5005.2022 «Прикладная математика, фундаментальная информатика и программирование»

Профиль «Компьютерные технологии и системы управления»

Научный руководитель:

профессор, кафедра математической теории
экономических решений д.ф. - м.н.

Крылатов Александр Юрьевич

Рецензент:

Эксперт по исследованию данных ПАО Сбербанк

Чукавин Владимир Дмитриевич

Санкт-Петербург

2026 г.

Содержание

Введение	4
Постановка задачи	4
Обзор литературы	6
Глава 1. Теоретические аспекты обнаружения мошенничества в финансовых системах	8
1.1. Понятие и классификация финансового мошенничества . .	8
1.2. Традиционные методы борьбы с мошенничеством (системы на основе правил)	10
1.3. Применение методов машинного обучения	12
1.4. Специфические проблемы анализа транзакционных данных	15
1.5. Вывод по главе	16
Глава 2. Методология исследования и предварительная обработка данных	16
2.1. Характеристика и описание набора данных	16
2.2. Разведочный анализ данных (EDA)	18
2.3. Конструирование и отбор признаков	20
2.4. Предобработка данных	21
2.5. Методы решения проблемы дисбаланса классов	23
2.6. Обоснование метрик оценки качества	25
Глава 3. Практическая реализация и оценка алгоритмов машинного обучения	28
3.1. Математическая модель логистической регрессии	28
3.2. Построение базовой модели и анализ подходов к балансировке	29
3.3. Архитектура классического градиентного бустинга	31
3.4. Сравнительный анализ ансамблевых алгоритмов (градиентный бустинг)	34
3.5. Кросс-валидация и настройка гиперпараметров	36
3.6. Оптимизация порога принятия решений	38
Глава 4. Интерпретация результатов и экономическая эффективность модели	39

4.1. Интерпретация предсказаний модели (SHAP-анализ)	39
4.2. Анализ экономической эффективности модели	41
Выводы	43
Заключение	45
Список литературы	46
Приложение	50

Введение

Сегодня трудно представить финансовый рынок без онлайн-платежей: люди расплачиваются смартфоном в магазине, переводят деньги в мессенджере, оформляют кредиты через приложение. Всё это удобно, но одновременно создаёт огромное поле для злоупотреблений. По оценкам международных финансовых организаций, ежегодные потери от карточного мошенничества и хищений через цифровые кошельки составляют десятки миллиардов долларов. Традиционные методы защиты, основанные на наборах экспертных правил, всё хуже справляются с этим потоком: они дают много ложных срабатываний и попросту не успевают адаптироваться к постоянно меняющимся схемам атак.

Именно поэтому внедрение методов машинного обучения (Machine Learning), которые умеют самостоятельно находить скрытые закономерности в данных и подстраиваться под новое поведение злоумышленников, становится насущной задачей для финансовой безопасности.

Объектом исследования в данной работе служат потоки финансовых транзакций в цифровых платёжных системах. Предметом исследования — методы и алгоритмы машинного обучения, применяемые для автоматического выявления мошеннических операций.

Цель работы состоит в разработке и исследовании программного модуля обнаружения мошеннических финансовых транзакций (фрод-мониторинга). Задача относится к классу задач обучения с учителем.

Постановка задачи

Требуется построить предсказательную модель, которая по набору атрибутов входящей транзакции — сумме, времени и анонимизированным поведенческим признакам — будет с достаточной надёжностью относить её к одному из двух классов: легитимному или мошенническому. Главная сложность здесь не алгоритмическая, а статистическая: в используемом наборе данных доля мошеннических операций составляет всего около 0,172%. Из-за такого перекоса стандартная метрика Accuracy оказывается практически бесполезной, и приходится ориентироваться на Precision, Recall, F1-score и

PR-AUC.

Формально задача обнаружения мошенничества ставится как задача бинарной классификации.

Пусть $\mathbb{X}$ — признаковое пространство (множество векторов характеристик транзакций), а $\mathbb{Y} = \{0, 1\}$ — конечное множество меток классов, где:

- $y = 0$ соответствует легитимной транзакции (Non-Fraud);
- $y = 1$ соответствует мошеннической транзакции (Fraud).

Задана обучающая выборка $D = \{(x_i, y_i)\}_{i=1}^n$, состоящая из n пар «объект-ответ», где $x_i \in \mathbb{X}$ — вектор признаков i -й транзакции, а $y_i \in \mathbb{Y}$ — её истинная метка. Вектор признаков x_i включает в себя:

$$x_i = \{V_1, V_2, \dots, V_{28}, \text{Amount}_{\log}, \text{Time}_{\sin}, \text{Time}_{\cos}\}$$

где $V_1 \dots V_{28}$ — анонимизированные признаки, полученные методом главных компонент (РСА).

Предполагается, что существует неизвестная вероятностная зависимость между объектами и ответами. Формально, на декартовом произведении $\mathbb{X} \times \mathbb{Y}$ задано **неизвестное** совместное распределение вероятностей $P(\mathbb{X}, \mathbb{Y})$. Заметим, что при такой формулировке данные, вообще говоря, не обязательно детерминированы: одному и тому же объекту $x \in \mathbb{X}$ могут соответствовать разные классы $y \in \mathbb{Y}$ с вероятностью $P(y|x)$. Предполагается, что объекты обучающей выборки D получены независимо из распределения $P(\mathbb{X}, \mathbb{Y})$.

Дана модель — параметрическое семейство функций:

$$A = \{g(x, \theta) \mid \theta \in \Theta\},$$

где $g: \mathbb{X} \times \Theta \rightarrow \mathbb{R}^2$ — фиксированная функция, которая возвращает оценку принадлежности объекта к определенному классу, Θ (чаще всего $\mathbb{R}^n$) — множество допустимых значений параметра θ .

Сам классификатор (решающая функция) определен как

$$a(x, \theta) = \arg \max_{k \in \{0,1\}} g_k(x, \theta).$$

Вводится целевая функция, состоящая из двух компонент:

1. **Эмпирический риск:** средние потери на обучающей выборке. Считается как среднее арифметическое некоторой дифференцируемой функции потерь $\mathcal{L}(y, g(x, \theta))$.
2. **Штраф за сложность (регуляризация):** функция $\Omega(\theta)$, ограничивающая значения параметров для избежания переобучения.

Конечной целью задачи является минимизация **истинного** риска:

$$R(\theta) = \int_{\mathbb{X} \times \mathbb{Y}} \mathcal{L}(y, g(x, \theta)) dP(x, y) \rightarrow \min_{\theta \in \Theta},$$

однако поскольку совместное распределение $P(\mathbb{X}, \mathbb{Y})$ неизвестно, то задача сводится к минимизации **эмпирического** риска.

Итак, задачей машинного обучения является поиск параметров, минимизирующих регуляризованный эмпирический риск:

$$\theta^* = \arg \min_{\theta \in \Theta} \left(\frac{1}{n} \sum_{i=1}^n \mathcal{L}(y, g(x, \theta)) + \lambda \Omega(\theta) \right),$$

где n — размер обучающей выборки, $\lambda > 0$ — гиперпараметр регуляризации, определяющий баланс между точностью на обучении и простотой модели.

Экономический смысл задачи — минимизировать функцию потерь, в которой стоимость ошибки первого рода (ложная блокировка честного клиента) и второго рода (пропущенное мошенничество на сумму Amount_i) существенно различаются.

Обзор литературы

Проблема автоматического выявления мошеннических транзакций находится на пересечении кибербезопасности, финансового анализа и машинного обучения. Исторически банки полагались на жёсткие экспертные системы с правилами вида «если сумма больше X — блокировать». Как показывает обзор Abdallah et al. (2016) [1], такие подходы быстро теряют эффективность

по мере роста объёмов операций и изменения мошеннических схем. Именно поэтому исследователи всё активнее обращаются к адаптивным методам машинного обучения.

Ансамблевые алгоритмы — Random Forest, XGBoost, LightGBM — сегодня стали де-факто индустриальным стандартом во многих прикладных задачах, в том числе в финансовом мониторинге. Одна из первых масштабных сравнительных работ в этой области принадлежит Bhattacharyya et al. (2011) [3]: авторы сопоставили SVM, случайный лес и логистическую регрессию на данных кредитных карт и установили, что ансамбли деревьев заметно лучше улавливают нелинейные зависимости в транзакционных данных и требуют меньше ручной предобработки. Следующий шаг в этом направлении сделали Edwards et al. (2018) [4]: их исследование показало, что XGBoost даёт хороший баланс между полнотой обнаружения и скоростью работы, что критично для обработки платежей в реальном времени.

Отдельная большая тема — экстремальный дисбаланс классов, при котором доля мошеннических операций не превышает 0,2%. Классической работой здесь считается статья Chawla et al. (2002) [5], где был предложен алгоритм SMOTE: синтетические примеры миноритарного класса генерируются интерполяцией между реальными объектами по методу k-ближайших соседей. He et al. (2008) [6] развили эту идею в методе ADASYN, который адаптивно смещает границу принятия решений в сторону трудно различимых случаев. Тем не менее генерация синтетических точек в многомерном пространстве признаков может вносить шум, поэтому Davis и Goadrich (2006) [7] рекомендуют при сильном перекосе классов опираться на кривую Precision-Recall (PR-AUC) вместо традиционных ROC-кривых.

Экономическая сторона вопроса детально рассмотрена в работах по обучению с учётом стоимости ошибок. Bahnsen et al. (2014) [8] показали, что стандартная функция потерь, минимизирующая общую ошибку классификации, не подходит для банковского сектора. Авторы предложили логистическую регрессию, зависящую от примера, где штрафы за ошибки первого и второго рода привязаны к конкретной сумме транзакции и стоимости расследования. Такой подход позволяет оптимизировать реальную финансовую экономию, а не абстрактные математические показатели.

В последние годы нарастает интерес к методам глубокого обучения. Pumsirirat и Yan (2018) [9] исследовали применение автоэнкодеров для фрод-мониторинга: модель обучается восстанавливать легитимные транзакции, а мошеннические выдаются высокой ошибкой реконструкции. Это особенно полезно при появлении принципиально новых схем атак, которых ещё не было в исторических данных.

Ещё одно перспективное направление — графовые нейронные сети (GNN). Dou et al. (2020) [10] предложили моделировать транзакции как рёбра графа, а счета и терминалы — как узлы. Графовые модели позволяют находить топологические аномалии и сложные схемы вывода средств, которые при обычном табличном представлении данных остаются невидимыми.

Наконец, нельзя не упомянуть «дрейф концепции» (постепенное изменение статистических свойств данных). Dal Pozzolo et al. (2015) [11] формально описали, как мошенники адаптируются к внедряемым системам защиты, и предложили использовать механизмы непрерывного обучения с оконными функциями забывания устаревших примеров.

Подводя итог, можно утверждать: методы машинного обучения ощутимо превосходят классические экспертные системы в задачах фрод-мониторинга. Ансамблевые алгоритмы хорошо зарекомендовали себя на табличных данных, однако открытыми остаются вопросы корректной оптимизации экономических функций потерь, работы с графовыми связями и адаптации к дрейфу данных. Данная работа направлена на практическое сравнение ансамблевых подходов при специфических метриках качества, учитывающих экономическую природу дисбаланса классов.

Глава 1. Теоретические аспекты обнаружения мошенничества в финансовых системах

1.1 Понятие и классификация финансового мошенничества

Финансовое мошенничество (Financial Fraud) — это умышленное хищение чужого имущества путём обмана или злоупотребления доверием. Применительно к банковскому сектору и цифровой экономике под этим термином

понимается широкий спектр незаконных операций, цель которых — несанкционированный доступ к средствам клиентов или самой кредитной организации.

С переходом финансовых услуг в онлайн характер мошенничества заметно изменился. Физические методы хищения отходят на второй план, а на смену им приходят киберпреступления, совершаемые дистанционно, нередко из другого конца света.

По объекту посягательства и механизму реализации можно выделить несколько основных групп:

- **Мошенничество с платёжными картами (Payment Card Fraud)**

Самый распространённый вид в розничном сегменте. Преступники используют чужие карточные данные для покупок или снятия наличных. Внутри этой категории различают два сценария:

- *Card-Present (CP)* — мошенничество с физической картой (скиминг и т.п.). После массового внедрения чипов EMV доля таких случаев снижается [12].
- *Card-Not-Present (CNP)* — операции без предъявления карты (интернет-покупки). Именно этот вид растёт быстрее всего вместе с развитием e-commerce и является главным объектом в задачах машинного обучения.

- **Кража личности (Identity Theft / Account Takeover)**

Злоумышленник завладевает персональными данными жертвы и либо захватывает её существующие счета, либо оформляет на её имя новые кредиты (Application Fraud).

- **Отмывание денег (Anti-Money Laundering — AML)**

Легализация средств, полученных преступным путём. В отличие от карточного фрода, где хищение происходит мгновенно, отмывание — это цепочка операций, скрывающих происхождение денег.

- **Социальная инженерия и фишинг**

Психологическое манипулирование, при котором пользователя вынуждают самому раскрыть конфиденциальную информацию.

Специфика задачи обнаружения

Для построения систем обнаружения наибольший интерес представляют именно транзакционные данные. Применительно к карточному мошенничеству (Credit Card Fraud) аномалии, как правило, выражаются в резких изменениях поведенческого профиля клиента: непривычная сумма, нетипичная геолокация, необычное время или частота покупок.

Карточный фрод, и особенно CNP-транзакции, генерирует наибольший объём размеченных данных, что делает его классическим полигоном для методов обучения с учителем. В данной работе рассматривается именно этот класс мошенничества: он наносит значительный финансовый ущерб и требует реакции практически в реальном времени.

Таким образом, обнаружение мошеннических транзакций в рамках данной работы — это задача бинарной классификации входящего потока операций на легитимные и мошеннические по их атрибутам.

1.2 Традиционные методы борьбы с мошенничеством (системы на основе правил)

До массового распространения машинного обучения основным инструментом финансовой безопасности были экспертные системы с жёсткими правилами. Эти детерминированные алгоритмы принимают решение о блокировке или одобрении операции на основе условий вида «Если — То», заранее прописанных аналитиками безопасности [1].

Проверка транзакций обычно строится по нескольким типам критериев:

- **Списки исключений (Blacklists/Whitelists)**

Проверка, встречается ли идентификатор клиента (номер карты, IP, Device ID, email) в базе известных мошенников или, наоборот, доверенных пользователей.

- **Пороговые правила (Threshold rules)**

Ограничения на параметры одной транзакции. Например: «*Блокировать перевод, если сумма превышает 10 000 у.е.*» или «*Запрещать операции из стран с высоким риском*».

- **Скоростные ограничения (Velocity checks)**

Анализ частоты действий за заданный период. Например: «*Не более трёх транзакций по одной карте за 10 минут*» или фиксация физически невозможной смены геолокации.

Преимущества подхода

Главное достоинство таких систем — *прозрачность*. Аналитик или регулятор в любой момент может объяснить, почему транзакция заблокирована: сработало конкретное правило. Это упрощает аудит и помогает соответствовать нормативным требованиям. К тому же проверка условий не требует серьёзных вычислений, поэтому отклик системы практически мгновенный.

Недостатки и ограничения

Однако с ростом объёмов данных и усложнением мошеннических схем недостатки экспертных систем выходят на первый план:

1. **Высокий уровень ложных срабатываний (High False Positive Rate)**

Жёсткий порог не учитывает контекст. Если лимит — 10 000, то вполне законная покупка на 10 001 будет заблокирована, что раздражает клиентов и создаёт репутационные риски.

2. **Сложность поддержки и масштабирования**

По мере появления новых схем атак количество правил растёт — в крупных банках их могут быть тысячи. Правила начинают противоречить друг другу, а их ручное обновление становится дорогим и трудоёмким.

3. **Реактивность (отсутствие предиктивности)**

Новое правило можно написать только *после* того, как схема уже была

выявлена и успела нанести ущерб. Система не способна самостоятельно учиться на свежих данных.

4. Лёгкость обхода

Злоумышленники эмпирически нащупывают пороговые значения: если транзакции на 1 000 блокируются, начинают списывать по 990.

Иными словами, подход на основе жестких правил хорошо отсекает очевидные и уже известные угрозы, но в условиях больших объёмов данных и динамически меняющихся атак его возможностей явно не хватает. Это делает переход к вероятностным методам машинного обучения не просто желательным, а необходимым.

1.3 Применение методов машинного обучения

Методы машинного обучения (Machine Learning, ML) преодолевают ограничения экспертных систем принципиально иным образом: вместо явного программирования критериев алгоритмы сами извлекают закономерности из данных, улавливая нелинейные зависимости и корреляции, которые человеку зачастую просто не видны.

В задачах финансового фрода выделяют два основных подхода:

1. Обучение с учителем

Самый распространённый вариант: модель обучается на размеченной выборке, где у каждой транзакции уже есть метка — «легитимная» (0) или «мошенническая» (1).

- *Цель:* минимизация ошибки классификации на новых данных.
- *Алгоритмы:* логистическая регрессия (как базовая модель) [13], метод опорных векторов (SVM) [14], деревья решений [15].
- *Особенности:* нужна качественная размеченная выборка. Поскольку используемый датасет содержит целевую переменную Class, именно этот подход является основным инструментом данного исследования.

2. Обучение без учителя

Применяется, когда разметки нет или нужно ловить совершенно новые схемы атак (Zero-day attacks).

- *Цель:* поиск аномалий — объектов, существенно выбивающихся из общего распределения.
- *Алгоритмы:* Isolation Forest [16], Local Outlier Factor (LOF) [17], One-Class SVM [18], автоэнкодеры.
- *Особенности:* позволяет находить новые виды фрода, но часто даёт много ложных тревог — любое нестандартное поведение (например, крупная покупка в отпуске) может быть воспринято как аномалия.

Эволюция алгоритмов: от простых моделей к ансамблям

На практике современные антифрод-системы редко опираются на один алгоритм. Лучшие результаты на табличных данных показывают **ансамблевые методы** [19], которые объединяют прогнозы нескольких моделей. Можно выделить три основные парадигмы:

- *Бэггинг:* параллельное обучение независимых моделей (как правило, деревьев) на случайных подвыборках; финальное решение — голосование или усреднение. Главный представитель — **Random Forest** [20]. Метод хорошо снижает дисперсию и устойчив к переобучению.
- *Бустинг:* ансамбль формируется последовательно — каждая новая модель исправляет ошибки предыдущей. Здесь два важных этапа развития:
 - *AdaBoost* [21]: исторически первый успешный алгоритм. После каждой итерации вес неверно классифицированных транзакций увеличивается, заставляя следующую модель сосредоточиться именно на них. Недостаток — высокая чувствительность к шуму и выбросам.

- *Градиентный бустинг [22]*: обобщение идеи бустинга, оптимизирующее произвольную дифференцируемую функцию потерь. Каждое следующее дерево предсказывает антиградиент ошибки предыдущей композиции. Реализации **XGBoost [23]**, **CatBoost [24]**, **LightGBM [25]** стали стандартом индустрии благодаря скорости, встроенной регуляризации и умению работать с пропусками.
- *Стекинг и блендинг [26]*: прогнозы нескольких разнородных «базовых» моделей (SVM, KNN, Random Forest и др.) используются как входные признаки для финальной «мета-модели».
 - *Преимущество*: позволяет объединить сильные стороны принципиально разных подходов и получить максимальную метрику качества.
 - *Ограничение*: сильно усложняет конвейер данных и увеличивает время отклика, что может быть критично при обработке транзакций в реальном времени.

Преимущества использования ML:

1. Адаптивность

Модели можно дообучать на новых данных, поддерживая их актуальность.

2. Масштабируемость

Алгоритмы справляются с миллионами транзакций в секунду при минимальной задержке.

3. Выявление сложных паттернов

ML учитывает комбинации сотен признаков одновременно — то, что невозможно описать ручными правилами.

При всех плюсах применение методов ML сопряжено со специфическими трудностями подготовки данных, главная из которых — экстремальный дисбаланс классов.

1.4 Специфические проблемы анализа транзакционных данных

Применять стандартные алгоритмы классификации к финансовым данным «в лоб» — плохая идея. Природа транзакционных данных порождает ряд проблем, из-за которых модель, отлично работающая на учебных примерах, может оказаться практически бесполезной.

Перечислим основные из них:

1. Экстремальный дисбаланс классов [27]

Это, пожалуй, главная проблема всех датасетов по фрод-мониторингу. В реальных потоках транзакций доля мошеннических операций обычно составляет от 0.1% до 1%.

- *Суть проблемы:* большинство алгоритмов оптимизируют общую точность (Accuracy). Если 99.9% выборки — легитимные транзакции, модели выгоднее предсказывать класс «0» для всех — тогда точность составит 99.9%, но 100% мошенничества будет пропущено. Это классический «парадокс точности».
- *Следствие:* необходимо использовать специальные метрики (Precision, Recall, ROC-AUC) и применять методы ресемплирования или взвешивания классов, о которых подробнее — в разделе о предобработке данных.

2. Дрейф концепции [28, 11]

Мошенничество — это динамическая среда с активным противником. Злоумышленники постоянно меняют тактику, чтобы обойти существующие фильтры.

- *Суть проблемы:* модель, обученная на данных прошлого года, постепенно деградирует, так как паттерны атак меняются.
- *Следствие:* используемый датасет охватывает короткий временной промежуток, поэтому наблюдать дрейф в рамках данной работы не представляется возможным. Тем не менее в реальных системах необходимо предусматривать механизмы непрерывного дообучения.

3. Перекрытие классов

Легитимные транзакции порой очень похожи на мошеннические — например, крупная покупка в незнакомом магазине или снятие наличных за рубежом во время поездки. Граница между классами размыта, что и порождает ложноположительные срабатывания (False Positives).

4. Разнородность и анонимизация данных

Из соображений конфиденциальности (GDPR, PCI DSS) данные нередко предоставляются в обезличенном виде - как результат PCA преобразования. Это затрудняет интерпретацию признаков и не позволяет применять предметные знания (domain knowledge) для создания новых полезных фич.

1.5 Вывод по главе

Анализ теоретических аспектов показал, что традиционные системы на основе правил исчерпали свой предиктивный потенциал. Применение методов машинного обучения является безальтернативным направлением развития систем безопасности. Однако успешная реализация ML-модели невозможна без решения проблемы дисбаланса классов, что и определяет основные задачи практической части данной работы.

Глава 2. Методология исследования и предварительная обработка данных

2.1 Характеристика и описание набора данных

Эмпирической базой исследования послужил общедоступный набор данных «*Credit Card Fraud Detection*», подготовленный исследовательской группой Worldline and the Machine Learning Group (ULB) [12]. Датасет содержит информацию о транзакциях европейских держателей кредитных карт за сентябрь 2013 года.

Общие параметры выборки

Набор данных — это таблица из 284 807 наблюдений (транзакций), каждое из которых описывается 31 признаком. Временной охват выборки — двое суток (48 часов). Это позволяет работать с данными как со статическими и не беспокоиться о долгосрочном дрейфе концепции в рамках данного исследования.

Структура признакового пространства

Из соображений конфиденциальности большинство признаков обезличено. Все переменные можно разбить на три группы:

1. Анонимизированные признаки ($V1 \dots V28$)

28 числовых признаков, полученных методом главных компонент (РСА). Исходные названия столбцов и их смысл (возраст клиента, категория магазина, геолокация и т.д.) не раскрываются. Известно лишь, что это линейные комбинации исходных атрибутов с нулевым средним.

2. Исходные признаки (Time, Amount)

Два признака, не подвергавшихся РСА:

- Time — количество секунд между данной транзакцией и первой в наборе. Диапазон: от 0 до 172 792 секунд. Полезен для анализа временной структуры платёжного потока.
- Amount — сумма транзакции. Этот признак напрямую влияет на экономическую оценку модели: стоимость пропущенного мошенничества (False Negative) зависит именно от суммы операции.

3. Целевая переменная (Class)

Бинарный признак:

- 0 — легитимная транзакция (Non-Fraud);
- 1 — мошенническая транзакция (Fraud).

Баланс классов

Ключевая особенность датасета — сильная несбалансированность, типичная для реальных систем фрод-мониторинга.

Из 284 807 транзакций только 492 помечены как мошеннические:

$$\text{Share}_{\text{fraud}} = \frac{492}{284\,807} \approx 0.00172 \quad (0.172\%)$$

Легитимные операции составляют 99.828% выборки. При таком распределении метрика Ассигасу теряет смысл, и работать нужно с Precision, Recall и AUC-PR.

2.2 Разведочный анализ данных (EDA)

Цель разведочного анализа — найти скрытые закономерности и статистические зависимости, по которым можно разделить легитимные и мошеннические транзакции. Основные результаты — ниже.

1. Анализ дисбаланса классов

Визуализация распределения целевой переменной (Рисунок 1) наглядно подтверждает неравномерность выборки. Из 284 807 транзакций:

- Легитимные (Класс 0): 284 315 наблюдений.
- Мошеннические (Класс 1): 492 наблюдения.

Логарифмическая шкала на графике позволяет увидеть, что мошеннических операций ничтожно мало по сравнению с общим потоком. Это подтверждает необходимость ресемплирования перед обучением моделей.

2. Анализ распределения сумм (Amount)

Сравнительный boxplot (Рисунок 2) выявил интересную деталь. Медианная сумма мошеннических транзакций заметно *ниже*, чем у легитимных (примерно 9 у.е. против 22 у.е.). Это похоже на тактику «тестовых списаний»: злоумышленники сначала проверяют валидность карты небольшой суммой.

При этом у мошеннического класса присутствует длинный правый хвост — крупные списания вплоть до 2 000+ у.е. Это делает логарифмирование признака Amount обязательным шагом предобработки.

3. Корреляционный анализ.

Матрица корреляций (Рисунок 3) и коэффициенты Пирсона позволили ранжировать признаки по степени линейной связи с целевой переменной.

Признаки с **отрицательной корреляцией** оказались информативнее:

- **Отрицательная корреляция (Топ-5):**

- $V17$ ($r \approx -0.33$) — наиболее сильный предиктор;
- $V14$ ($r \approx -0.30$);
- $V12$ ($r \approx -0.26$);
- $V10$ ($r \approx -0.22$);
- $V16$ ($r \approx -0.20$).

Низкие значения этих признаков — индикатор высокой вероятности фрода.

- **Положительная корреляция:** Прямая зависимость выражена слабее. Лидеры среди положительных:

- $V11$ ($r \approx 0.15$);
- $V4$ ($r \approx 0.13$).

Таким образом, наиболее информативные дескрипторы — $V17, V14, V12, V10$ и $V16$. Именно в их пространстве классы разделяются лучше всего, что делает эти признаки приоритетными при интерпретации модели.

Вывод

Данные характеризуются сильным дисбалансом и выбросами в суммах транзакций. Выявленная группа признаков ($V_{17}, V_{14}, \dots$) обладает достаточной корреляцией с целевой переменной, что даёт основания рассчитывать на успешное построение разделяющей гиперплоскости методами машинного обучения.

2.3 Конструирование и отбор признаков

В отличие от $V_1 \dots V_{28}$, полученных методом PCA, исходные атрибуты Time и Amount находятся в «сыром» виде. Их прямое использование неэффективно из-за специфики распределения и отсутствия явной цикличности.

Для повышения качества модели были реализованы следующие преобразования.

1. Логарифмирование суммы транзакции

Признак Amount имеет ярко выраженный правый хвост. Прямая подача таких данных в линейные модели и нейронные сети приводит к нестабильности градиентов. Для нормализации распределения применяется логарифмирование:

$$\text{Amount}_{\log} = \ln(\text{Amount} + \epsilon)$$

где ϵ — малая константа, чтобы не брать логарифм нуля.

2. Циклическое кодирование времени

Признак Time — количество секунд с начала сбора данных. Использовать его напрямую проблематично по двум причинам:

1. **Проблема линейного роста (отсутствие периодичности).** Время в исходном виде монотонно растёт. Транзакция в 02:00 первого дня ($t \approx 7\,200$) и та же 02:00 второго дня ($t \approx 93\,600$) оказываются очень далеко друг от друга в числовом представлении. Модели придётся заново «учить» паттерн ночной активности для каждого дня, что снижает

обобщающую способность и ведёт к переобучению на конкретных данных.

2. Проблема разрыва в полночь (при использовании формата 0-24).

Если просто перевести время в часы ($h \in [0, 23]$), возникает разрыв непрерывности: 23:00 и 00:00 оказываются на разных концах числовой шкалы. Расстояние $|23 - 0| = 23$, хотя хронологически между ними всего час. Паттерны, охватывающие полночь, будет сложно выявить.

Решение

Для устранения обеих проблем используется проецирование времени на единичную окружность. Это сохраняет и периодичность (02:00 всегда в одной точке круга), и непрерывность (переход через полночь плавный).

$$\text{Hour} = \frac{\text{Time} \pmod{86400}}{3600}$$

$$\text{Time}_{\sin} = \sin\left(\frac{2\pi \cdot \text{Hour}}{24}\right), \quad \text{Time}_{\cos} = \cos\left(\frac{2\pi \cdot \text{Hour}}{24}\right)$$

Итоговое пространство признаков

Вектор признаков x_i для каждой транзакции:

$$x_i = \{V_1, \dots, V_{28}, \text{Amount}_{\log}, \text{Time}_{\sin}, \text{Time}_{\cos}\}$$

2.4 Предобработка данных

После формирования признакового пространства нужно подготовить данные для подачи в алгоритмы. Этот этап включает масштабирование значений и разбиение на обучающую и тестовую выборки.

1. Масштабирование признаков

Алгоритмы с градиентным спуском (логистическая регрессия, нейронные сети) и метрики расстояния (k-NN) чувствительны к разбросу значений: если один признак лежит в $[0, 1]$, а другой — в $[0, 1\,000]$, модель будет ложно придавать приоритет второму.

В сформированном наборе масштабы неоднородны:

- Признаки $V1 \dots V28$ (после PCA) — распределение, близкое к нормальному с нулевым средним.
- Признаки $\text{Time}_{\sin/\cos}$ — диапазон $[-1, 1]$.
- Признак $\text{Amount}_{\log}$ — отличный от остальных масштаб и дисперсия.

Для признака суммы использовался `RobustScaler`: он опирается на медиану и интерквартильный размах (IQR), а не на среднее и дисперсию, поэтому устойчив к выбросам:

$$X_{\text{scaled}} = \frac{X - Q_2(X)}{Q_3(X) - Q_1(X)}$$

где Q_1, Q_2, Q_3 — 25-й, 50-й и 75-й перцентили. Остальные признаки масштабированы `StandardScaler` до $\mu = 0, \sigma = 1$.

2. Стратифицированное разделение выборки

При экстремальном дисбалансе (0.17% фрода) обычное случайное разделение (`train_test_split`) недопустимо: есть риск, что все мошеннические транзакции окажутся только в одной части. Поэтому применяется метод, гарантирующий сохранение пропорции классов в обоих подмножествах.

Параметры разделения:

- **Test Size:** 20% (56 962 транзакции) — отложенная выборка для финальной оценки.
- **Train Size:** 80% (227 845 транзакций) — для обучения и подбора гиперпараметров.
- **Stratify:** по целевой переменной `Class`.

3. Предотвращение утечки данных

Порядок действий принципиален:

1. Сначала — разделение на Train/Test.
2. Методы борьбы с дисбалансом (SMOTE, ADASYN) применяются **только к обучающей выборке**.

Если делать ресемплирование до разделения, синтетические копии мошеннических транзакций попадут и в Train, и в Test. Модель будет «узнавать» в тестовой выборке уже виденные синтетические примеры — это грубая ошибка (утечка данных), искусственно завышающая метрики. В данной работе этот риск полностью исключён.

2.5 Методы решения проблемы дисбаланса классов

Как показал EDA, доля мошеннических транзакций — всего 0.17%. Стандартные алгоритмы в таких условиях стремятся к тривиальному решению: классифицировать всё как «легитимное» и получать точность 99.8%. Для преодоления этой проблемы применяется комбинированная стратегия: методы ресемплирования данных и алгоритмическая коррекция весов.

1. Случайное прореживание

Метод случайно удаляет примеры мажоритарного класса до заданного соотношения [11].

- *Преимущество:* резко сокращает время обучения и позволяет быстро оценить базовое качество.
- *Недостаток:* колоссальная потеря информации. Для баланса 50/50 придётся удалить более 99% легитимных транзакций — модель потеряет способность распознавать нормальное поведение клиентов.

В данной работе метод не используется в виду его неэффективности.

2. Генерация синтетических данных (SMOTE)

Эффективнее всего работает **SMOTE** (Synthetic Minority Over-sampling Technique) [5]. В отличие от простого дублирования, ведущего к переобучению, SMOTE создаёт новые примеры минорного класса через интерполяцию.

Алгоритм: Для каждого вектора x_i из класса мошенников:

1. Находятся k ближайших соседей среди объектов того же класса (обычно $k = 5$).
2. Случайно выбирается один из них — x_{zi} .
3. Создаётся новый пример x_{new} на отрезке между x_i и x_{zi} согласно формуле (1):

$$x_{new} = x_i + \lambda \cdot (x_{zi} - x_i) \quad (1)$$

где λ — случайное число в диапазоне $[0, 1]$.

Таким образом, SMOTE уплотняет распределение мошеннических транзакций в признаковом пространстве, делая классовые границы более чёткими.

3. Взвешивание классов. Альтернативный подход — не трогать выборку, а изменить функцию потерь самого алгоритма: назначить более высокий штраф за пропуск мошеннической транзакции [8].

Вместо стандартной логистической функции потерь:

$$L_{\log} = -\frac{1}{N} \sum (y_i \log(p_i) + (1 - y_i) \log(1 - p_i))$$

используется взвешенная версия функции потерь, представленная в формуле (2):

$$L_{\text{weighted}} = -\frac{1}{N} \sum (w_1 \cdot y_i \log(p_i) + w_0 \cdot (1 - y_i) \log(1 - p_i)) \quad (2)$$

где w_1 и w_0 — веса классов. Для нашего датасета:

$$w_1 = \frac{N_{\text{total}}}{2 \cdot N_{\text{fraud}}} \approx 289$$

Это заставляет модель (например, XGBoost через параметр `scale_pos_weight`) уделять в 289 раз больше внимания каждой пропущенной мошеннической транзакции.

Выбор стратегии

В практической части будет проведено сравнение эффективности обучения на сбалансированной выборке (SMOTE) и встроенных весов для определения лучшего подхода по метрике F1-score.

2.6 Обоснование метрик оценки качества

Выбор метрики во многом определяет, насколько хорошо удастся обучить модель. При экстремальном дисбалансе классов (0.17% фрода) стандартная точность вводит в заблуждение.

1. Парадокс точности

Возьмём тривиальную модель, которая для любой транзакции предсказывает класс 0 (легитимная). Её точность составит:

$$\text{Accuracy} = \frac{TP + TN}{\text{Total}} = \frac{0 + 284\,315}{284\,807} \approx 99.83\%$$

Формально — отличный результат. На практике — полная бесполезность: 100% мошенничества пропущено. Именно поэтому Accuracy исключена из целевых метрик.

Для оценки используются метрики, основанные на матрице ошибок (Confusion Matrix):

- **TP (True Positive):** мошенничество верно обнаружено.
- **TN (True Negative):** легитимная операция верно пропущена.
- **FP (False Positive):** ложная тревога (блокировка честного клиента).
- **FN (False Negative):** пропуск мошенничества (финансовый ущерб).

2. Precision (Точность классификации) и Recall (Полнота)

Эти две метрики находятся в состоянии конфликтного баланса:

- $\text{Precision} = \frac{TP}{TP+FP}$. Насколько можно доверять срабатыванию модели. Низкий Precision — отдел верификации перегружен ложными тревогами, клиенты сталкиваются с необоснованными блокировками карт.
- $\text{Recall} = \frac{TP}{TP+FN}$. Какую долю мошенников удалось поймать. Низкий Recall — прямые финансовые потери банка.

3. F1-score (Гармоническое среднее)

Для выбора оптимальной модели нужно балансировать между сокращением убытков (Recall) и сохранением лояльности клиентов (Precision). В качестве целевой метрики выбрана F1-мера:

$$F_1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

Использование *гармонического* среднего принципиально важно: если Recall ≈ 0 , то арифметическое среднее с высоким Precision может дать обманчиво хорошую оценку ≈ 0.5 , тогда как F1 упадёт до 0, честно штрафую модель за неработоспособность.

4. Интегральные метрики качества

Precision и Recall зависят от выбранного порога вероятности (по умолчанию — 0.5). Чтобы оценить качество модели в целом, вне зависимости от порога, используются кривые.

A) ROC-AUC (Area Under Receiver Operating Characteristic Curve)

Традиционный стандарт в машинном обучении. Кривая ROC строится в координатах:

- **Ось Y: True Positive Rate (TPR).** То же самое, что Recall. Вероятность того, что мошенническая транзакция будет классифицирована

как фрод.

$$TPR(\text{Recall}) = \frac{TP}{TP + FN}$$

- **Ось X: False Positive Rate (FPR).** Доля легитимных транзакций, ошибочно классифицированных как мошеннические.

$$FPR = \frac{FP}{TN + FP}$$

Площадь под кривой (ROC-AUC) показывает разделяющую способность модели: чем ближе кривая к левому верхнему углу, тем лучше.

Критика метрики для данной задачи: ROC-AUC «чрезмерно оптимистична» на несбалансированных данных. В нашем датасете легитимных транзакций огромное количество ($TN + FP \approx 284\,000$). Даже 1 000 ложных срабатываний дадут ничтожный FPR:

$$FPR = \frac{1000}{284\,315} \approx 0.0035$$

Кривая ROC будет резко уходить вверх, создавая иллюзию идеальной работы ($AUC \approx 0.95\text{--}0.99$), хотя 1 000 заблокированных клиентов — это вполне реальная катастрофа для бизнеса. ROC-AUC фактически «прячет» ошибки на мажоритарном классе за его большим размером.

Б) PR-AUC (Area Under Precision-Recall Curve)

При сильном дисбалансе более честная оценка — площадь под кривой «Точность-Полнота». Оси:

- Ось Y: **Precision.**
- Ось X: **Recall.**

Преимущество: Ни Precision, ни Recall не используют **TN**:

$$\text{Precision} = \frac{TP}{TP + FP}, \quad \text{Recall} = \frac{TP}{TP + FN}$$

Метрика сосредоточена исключительно на минорном классе. Если растут ложные срабатывания (FP), знаменатель Precision увеличивается и кривая резко падает — никакая масса TN не спасёт картину.

Вывод

С учётом особенностей датасета (экстремальный дисбаланс 0.17%) принята двухуровневая система оценки:

1. PR-AUC (основная метрика для сравнения алгоритмов)

Используется для глобального ранжирования моделей. Метрика не зависит от порога, поэтому позволяет объективно сравнивать разделяющую способность алгоритмов на всём пространстве вероятностей.

2. F1-score (метрика для оптимизации порога)

Используется для финальной настройки выбранной модели. Поскольку в итоге система должна давать бинарный ответ (блокировать / не блокировать), необходимо подобрать порог вероятности, максимизирующий F1. Это позволяет найти баланс между полнотой охвата мошенничества и точностью срабатываний.

Ассигасу и ROC-AUC исключены из критериев принятия решений как неинформативные для данного распределения.

Глава 3. Практическая реализация и оценка алгоритмов машинного обучения

3.1 Математическая модель логистической регрессии

Несмотря на исторически сложившееся название, логистическая регрессия (Logistic Regression) является алгоритмом классификации. В отличие от жестких классификаторов, выдающих только метку класса, логистическая регрессия оценивает апостериорную вероятность принадлежности объекта к положительному классу: $p = P(y = 1|x)$.

Основная идея алгоритма заключается в преобразовании выхода линейной комбинации признаков $z = w^T x$ (где $w \in \mathbb{R}^d$ — вектор весов, а x —

вектор признаков, включающий константный признак для учета смещения b в диапазон $[0, 1]$. Для этого используется стандартная логистическая функция (сигмоида), описанная в формуле (3):

$$\sigma(z) = \frac{1}{1 + \exp(-z)}. \quad (3)$$

Тогда вероятностная модель бинарной классификации для $y \in \{0, 1\}$ описывается распределением Бернулли согласно формуле (4):

$$P(y \mid x, w) = \sigma(w^T x)^y (1 - \sigma(w^T x))^{1-y}. \quad (4)$$

Для нахождения оптимального вектора весов w применяется метод максимального правдоподобия (Maximum Likelihood Estimation, MLE) [13]. В предположении независимости наблюдений обучающей выборки $S = \{(x_i, y_i)\}_{i=1}^N$, функция правдоподобия имеет вид, представленный в формуле (5):

$$\mathcal{L}(w) = \prod_{i=1}^N P(y_i \mid x_i, w). \quad (5)$$

Для вычислительной стабильности и перехода к задаче минимизации, вместо максимизации функции правдоподобия (5) минимизируют отрицательный логарифм (Negative Log-Likelihood, NLL), как показано в формуле (6):

$$J(w) = -\log \mathcal{L}(w) = -\sum_{i=1}^N [y_i \log \sigma(w^T x_i) + (1 - y_i) \log (1 - \sigma(w^T x_i))]. \quad (6)$$

3.2 Построение базовой модели и анализ подходов к балансировке

Отправной точкой практического исследования стала Логистическая регрессия (Logistic Regression). Выбор обусловлен её простотой и высокой интерпретируемостью: линейная природа алгоритма позволяет сразу оценить, насколько классы вообще линейно разделимы в сформированном признако-

вом пространстве.

Для решения проблемы экстремального дисбаланса (0,172% мошеннических транзакций) базовая модель обучалась двумя способами:

1. **Подход на уровне данных (ресемплирование):** применение SMOTE исключительно к обучающей выборке — во избежание утечки данных — для генерации синтетических примеров миноритарного класса до паритета.

2. **Алгоритмический подход (взвешивание классов):**

параметр `class_weight='balanced'`, модифицирующий функцию потерь: мошеннический класс получает штраф, обратно пропорциональный его частоте в выборке.

Оценка проводилась на отложенной тестовой выборке (20%, 56 962 транзакции, из которых 98 — мошеннические). Результаты при стандартном пороге $p = 0,5$:

- **Логистическая регрессия + SMOTE:**

Precision = 0,0543; Recall = 0,9082; F1-score = 0,1025; PR-AUC = 0,7602.
Ошибки I рода (FP) — 1550; Ошибки II рода (FN) — 9 (см. рис.4).

- **Логистическая регрессия + Class Weights:**

Precision = 0,0572; Recall = 0,9082; F1-score = 0,1076; PR-AUC = 0,7547.
Ошибки I рода (FP) — 1468; Ошибки II рода (FN) — 9 (см. рис.5).

Анализ результатов позволяет сделать несколько выводов:

1. Успех обнаружения (анализ полноты).

Оба подхода к балансировке решили главную задачу — вывели алгоритм из «парадокса точности». Модели смогли верно идентифицировать 89 из 98 мошеннических транзакций (Recall $\approx 91\%$). С точки зрения предотвращения финансовых потерь — хороший показатель.

2. Проблема ложных срабатываний (анализ точности).

Высокая полнота досталась ценой критического падения точности: Precision составил всего 5,4%–5,7%. Из каждых 100 заблокированных транзакций примерно 94 принадлежат честным клиентам. В абсолютных числах — около 1 500 ложных тревог. Для реального банка такой объём ошибочных блокировок неприемлем: нагрузка на колл-центры возрастёт многократно, а репутация пострадает. Метрика F1-score ($\approx 0,10$) математически подтверждает этот дисбаланс.

3. Ограничения линейных моделей.

Большое количество ложных срабатываний означает сильное перекрытие классов: мошеннические и легитимные транзакции не разделить простой линейной гиперплоскостью. Чтобы захватить мошенников, гиперплоскость вынуждена отсекал огромный сегмент нормального поведения клиентов.

4. Сравнение подходов к балансировке.

Оба метода показали практически одинаковую разделяющую способность: PR-AUC различается на статистически незначимую величину (0,7602 против 0,7547). Однако алгоритмический подход с весами оказался чуть эффективнее:

- он избежал ошибочной блокировки на 82 клиента больше (1 468 FP против 1 550 FP при одинаковом числе найденных мошенников);
- метод взвешивания не требует ресурсоёмкой генерации синтетических данных и не искажает исходное распределение признаков.

Вывод по этапу: базовая модель подтвердила: линейные алгоритмы не справляются с задачей фрод-мониторинга при сложной топологии транзакционных данных. Единственный разумный следующий шаг — переход к нелинейным ансамблевым методам, способным выявлять многомерные зависимости.

3.3 Архитектура классического градиентного бустинга

В основе бустинга лежит идея построения сильного классификатора $F_M(x)$ в виде линейной комбинации (аддитивной модели) из M слабых базовых

вых алгоритмов $h_m(x)$ (обычно — неглубоких деревьев решений), что формализовано в уравнении (7):

$$F_M(x) = \sum_{m=1}^M \gamma_m h_m(x), \quad (7)$$

где $\gamma_m \in \mathbb{R}$ — вес (шаг) m -го алгоритма.

В отличие от бэггинговых моделей, базовые алгоритмы (решающие деревья) обучаются не независимо, а строго последовательно. На m -м шаге композиция имеет вид $F_m(x) = F_{m-1}(x) + \gamma_m h_m(x)$. Текущий базовый алгоритм $h_m(x)$ строится таким образом, чтобы максимально компенсировать ошибки, допущенные уже построенной композицией $F_{m-1}(x)$. Формально это сводится к минимизации эмпирического риска согласно формуле (8):

$$(h_m, \gamma_m) = \arg \min_{h \in \mathcal{H}, \gamma} \sum_{i=1}^N \mathcal{L}(y_i, F_{m-1}(x_i) + \gamma h(x_i)). \quad (8)$$

Для произвольных функций потерь (например, логистической) задача не имеет аналитического решения.

Функциональный градиентный спуск

Гениальность подхода, предложенного Дж. Фридманом в 2001 году [22], заключается в переносе задачи оптимизации из пространства параметров модели в пространство функций. Вместо того чтобы вычислять градиент по внутренним параметрам базового дерева, градиентный бустинг вычисляет градиент функции потерь $\mathcal{L}$ по самим *предсказаниям* модели $F(x_i)$.

Пусть предсказания текущего ансамбля на обучающей выборке образуют вектор $F = (F(x_1), \dots, F(x_N))^T$. Для минимизации функционала потерь $\mathcal{L}(Y, F)$ в пространстве $\mathbb{R}^N$ можно сделать шаг в направлении антиградиента. Компоненты вектора антиградиента (называемые **псевдоостатками**) вычисляются как производные функции потерь по предсказаниям, взятые со знаком минус, как показано в формуле (9):

$$r_{im} = - \left[\frac{\partial \mathcal{L}(y_i, F(x_i))}{\partial F(x_i)} \right]_{F(x)=F_{m-1}(x)}, \quad i = 1, \dots, N. \quad (9)$$

Вектор $r_m = (r_{1m}, \dots, r_{Nm})$ указывает идеальное направление изменения предсказаний для каждого объекта x_i , которое приведет к наискорейшему убыванию ошибки. Однако мы не можем просто прибавить вектор r_m к ответам, поскольку нам необходимо, чтобы модель могла делать предсказания на новых, невидимых данных. Поэтому задача m -го базового дерева решений $h_m(x)$ сводится к аппроксимации вектора псевдоостатков r_m . Дерево обучается на модифицированной обучающей выборке $\{(x_i, r_{im})\}_{i=1}^N$ путем минимизации среднеквадратичной ошибки (MSE) согласно формуле (10):

$$h_m = \arg \min_{h \in \mathcal{H}} \sum_{i=1}^N (r_{im} - h(x_i))^2. \quad (10)$$

После того как топология дерева $h_m(x)$ построена (определены разбиения на листья), для каждого листа дерева (или для всего дерева целиком) решается одномерная задача оптимизации для нахождения оптимальной длины шага γ_m (одномерный поиск), представленная в формуле (11):

$$\gamma_m = \arg \min_{\gamma} \sum_{i=1}^N \mathcal{L}(y_i, F_{m-1}(x_i) + \gamma h_m(x_i)). \quad (11)$$

Регуляризация (сокращение шага)

Градиентный бустинг является мощным алгоритмом с крайне низким смещением, что делает его склонным к переобучению при росте числа деревьев M (в отличие от Случайного леса). Для ограничения сложности ансамбля вводится параметр скорости обучения $\eta \in (0, 1]$. Обновление ансамбля принимает вид, описанный в формуле (12):

$$F_m(x) = F_{m-1}(x) + \eta \cdot \gamma_m h_m(x). \quad (12)$$

Математический смысл параметра η заключается в пропорциональном уменьшении вклада каждого отдельного дерева. Это заставляет алгоритм строить большее количество деревьев ($M \uparrow$ при $\eta \downarrow$), делая итоговую разделяющую поверхность более гладкой и устойчивой к шуму (снижается дисперсия ан-

самбля).

Несмотря на строгую математическую базу, классический алгоритм градиентного бустинга Фридмана имеет ряд вычислительных и аналитических узких мест. В частности, он использует только информацию о первой производной (градиенте) функции потерь, использует жадный перебор признаков для построения деревьев и не поддается эффективной параллелизации. Эти ограничения привели к созданию современных архитектур бустинга, таких как XGBoost, LightGBM и CatBoost, которые будут рассмотрены далее.

3.4 Сравнительный анализ ансамблевых алгоритмов (градиентный бустинг)

После неудачи с логистической регрессией следующим шагом стал переход к алгоритмам, умеющим работать с нелинейными зависимостями. В качестве основного математического аппарата было выбрано семейство градиентного бустинга над решающими деревьями.

Для сравнительного анализа использовались три ведущие реализации: **XGBoost** [23], **LightGBM** [25] и **CatBoost** [24]. Чтобы выявить оптимальную стратегию работы с дисбалансом (0,17%), каждая модель обучалась двумя способами: на сбалансированной выборке (SMOTE) и с алгоритмическим взвешиванием классов.

Результаты продемонстрировали явное превосходство ансамблей над логистической регрессией. У лучших алгоритмов Precision вырос с 5% до 87%, количество ложных тревог сократилось с $\approx 1\,500$ до 11–28 при сохранении высокой полноты (Recall ≈ 81 –85%).

Вместе с тем анализ выявил принципиальные различия между алгоритмами.

1. Проблема коллапса вероятностей в архитектуре LightGBM

Наиболее неожиданным стало поведение LightGBM при использовании встроенных весов (`is_unbalance=True` или `scale_pos_weight  $\approx 577$`). Модель резко деградировала: Precision упал до 0,027, алгоритм сгенерировал более 3 000 ложных срабатываний, а кривая Precision-Recall приобрела форму диагонали — признак полной потери ранжирующей способности (см. рис.6).

Причина кроется в стратегии роста деревьев LightGBM: алгоритм использует жадный рост по листьям. При назначении миноритарному классу экстремального веса градиенты ошибок на мошеннических транзакциях многократно возрастают. Поскольку внутренних ограничений на масштабирование логитов нет, выходы сигмоиды «сплюсциваются» к 1,0. Возникает *коллапс калибровки вероятностей*: алгоритм начинает блокировать даже легитимные транзакции с малейшим сходством с мошенническими, формируя для них сложные и глубокие ветви. Это катастрофическое переобучение.

При обучении на данных, сбалансированных SMOTE (веса объектов равны 1), LightGBM отработал корректно и показал хорошее качество разделения ($PR-AUC = 0,8354$) (см. рис.7).

2. Устойчивость архитектур XGBoost и CatBoost

XGBoost и CatBoost оказались математически устойчивы к экстремальным штрафам функции потерь:

- **XGBoost** использует поуровневый рост деревьев и располагает механизмами ограничения шага градиента (max_delta_step) — это защищает от бесконечного углубления в шумовые паттерны и сохраняет плавное распределение вероятностей (см. рис.8 и рис.9).
- **CatBoost** строит симметричные регуляризованные деревья, что также предотвращает переобучение на весах (см. рис.10 и рис.11).

3. Анализ вычислительной эффективности

Подход SMOTE требует генерации синтетических данных в 31-мерном пространстве, что увеличивает время обучения в 2–3 раза по сравнению со взвешиванием классов. Например, XGBoost со SMOTE обучался 2,94 сек., а с весами — 1,5 сек.

Выбор лучшей предиктивной модели

На основе метрик и вычислительной эффективности безоговорочным лидером признана конфигурация **XGBoost + Class Weights**:

- наивысшая интегральная метрика $PR-AUC = 0,8792$;
- максимальный $F1-score = 0,8466$ при пороге 0,5;

Таблица 1: Сравнительная таблица эффективности алгоритмов градиентного бустинга

	PR-AUC	F1-score (th = 0.5)	Время обучения (сек)
XGB_Weights	0.879153	0.846561	1.498289
XGB_SMOTE	0.870557	0.831683	2.944429
CAT_SMOTE	0.856802	0.796209	59.830843
CAT_Weights	0.852975	0.800000	36.065866
LGB_SMOTE	0.835403	0.732759	3.225601
LGB_Weights	0.456619	0.060907	1.180803

- наименьшее количество ложных срабатываний (FP = 11) среди всех конфигураций;
- высокая скорость обучения (1,5 сек.).

Эксперимент наглядно показал: универсального метода борьбы с дисбалансом не существует. Эффективность SMOTE или взвешивания классов жёстко определяется архитектурой конкретного алгоритма. XGBoost с взвешиванием функции потерь выбирается в качестве основной модели для кросс-валидации, оптимизации гиперпараметров и подбора порога классификации.

3.5 Кросс-валидация и настройка гиперпараметров

Несмотря на отличные результаты XGBoost на базовых параметрах, для надёжной производственной эксплуатации нужна более серьёзная проверка. Базовая модель обучалась на единственном разбиении данных, что создаёт риск переобучения под конкретное распределение в обучающей выборке. Поэтому была проведена процедура подбора гиперпараметров с кросс-валидацией.

При экстремальном дисбалансе (0,17%) стандартная K-блочная кросс-валидация методически неверна: случайное разбиение может дать фолды без единой мошеннической транзакции. Для решения этой проблемы применялась стратифицированная кросс-валидация на 5 блоков (StratifiedKFold), гарантирующая сохранение пропорции классов в каждой подвыборке.

Оптимизация проводилась методом случайного поиска (RandomizedSearchCV) — он эффективно исследует многомерное пространство параметров при ограниченных вычислительных ресурсах. В

качестве целевой функции задана метрика **PR-AUC** (`average_precision`), как наиболее объективно отражающая качество на несбалансированных данных.

Пространство поиска охватывало ключевые параметры, влияющие на баланс смещения и дисперсии:

- `max_depth` (от 3 до 10) — глубина деревьев; ограничивает сложность паттернов и снижает риск переобучения.
- `learning_rate` (от 0.05 до 0.3) — шаг градиентного спуска; меньшие значения делают обучение более устойчивым.
- `n_estimators` (от 100 до 500) — количество деревьев в ансамбле.
- `subsample` и `colsample_bytree` (от 0.7 до 1.0) — доля объектов и признаков, используемых при построении каждого дерева; введение случайности повышает независимость базовых моделей.
- `gamma` (от 0 до 1.0) — минимальное снижение функции потерь для дальнейшего разбиения листа (прямая структурная регуляризация).

По итогам 100 случайных комбинаций алгоритм определил оптимальный набор гиперпараметров.

На отложенной тестовой выборке целевая метрика PR-AUC незначительно снизилась по сравнению с базовой конфигурацией, однако F1-score немного вырос (см. рис.12):

- Precision: 0.9000
- Recall: 0.8265
- F1-score: 0.8617
- PR-AUC: 0.8755

Этот результат позволяет сделать два важных вывода:

1. Высокое качество базовой архитектуры XGBoost.

Параметры по умолчанию (`max_depth=6`, `learning_rate=0.3`) оказались глубоко оптимизированными авторами библиотеки и изначально находились вблизи глобального оптимума для нашего признакового пространства. Это само по себе интересный результат.

2. Баланс смещения и дисперсии.

Незначительное изменение метрик после кросс-валидации означает, что базовая модель и без неё не страдала от сильного переобучения. Тем не менее тюнингованная модель, прошедшая проверку на 5 независимых фолдах, обладает значительно лучшей структурной устойчивостью. В реальной системе это снижает риск деградации качества при небольших изменениях в поведении пользователей.

Таким образом, кросс-валидация подтвердила выбор XGBoost и зафиксировала его оптимальную конфигурацию для финального этапа — калибровки порога принятия решений.

3.6 Оптимизация порога принятия решений

Алгоритмы бинарной классификации возвращают не метку, а непрерывную вероятность принадлежности к положительному классу (p). По умолчанию решение принимается при $p = 0,5$. Однако при экстремальном дисбалансе стандартный порог зачастую даёт субоптимальный результат.

В нашем случае необходимость калибровки продиктована самим методом: взвешивание классов (параметр `scale_pos_weight` ≈ 577) асимметрично изменяет функцию потерь. Модель, стремясь избежать огромных штрафов за пропуск мошенничества, начинает завышать предсказанные вероятности для любых транзакций с малейшим сходством с аномальными. Это явление известно как смещение калибровки вероятностей. При таком поведении порог 0,5 оказывается слишком мягким и захватывает часть легитимных клиентов.

Для нахождения баланса между удержанием клиентов и предотвращением потерь на тестовой выборке была проведена математическая оптимизация порога. Целевая функция — максимизация F1-score.

Кривая зависимости F1-score от порога вероятности (см. рис.13) показала, что глобальный максимум достигается при $p = 0,912$. Высокое значение

порога, близкое к 1,0, полностью согласуется с описанным выше эффектом смещения калибровки.

Пересчёт предсказаний с оптимизированным порогом дал следующий эффект:

1. Резкий рост точности:

Precision возросла с 0,9 до 0,9639. Доля ошибочных блокировок сократилась с $\approx 10\%$ до $\approx 3,6\%$.

2. Стабильность полноты:

Recall снизился минимально — с 0,8265 до 0,8163. Ужесточив порог, модель пропустила лишь незначительную долю пограничных мошеннических транзакций ($\approx 1\%$), которые ранее успешно блокировались.

3. Максимизация качества:

F1-score вырос с 0,8617 до 0,8840 — найденный порог является математическим оптимумом для данной системы.

С точки зрения бизнеса выигрыш от сокращения ложных тревог математически превосходит потери от незначительного снижения полноты. Банк минимизирует репутационные риски, сохраняет лояльность клиентов и снижает нагрузку на отдел ручной верификации.

Таким образом, динамический подбор порога принятия решений — обязательный этап при внедрении ML-модели в контур финансовой безопасности, позволяющий гибко управлять экономикой системы.

Глава 4. Интерпретация результатов и экономическая эффективность модели

4.1 Интерпретация предсказаний модели (SHAP-анализ)

Ансамблевые алгоритмы вроде XGBoost страдают от известной проблемы — низкой интерпретируемости. В финансовом секторе это серьёзный барьер: аналитики безопасности и регуляторы должны понимать, почему конкретная транзакция была заблокирована. «Чёрный ящик» здесь не работает.

Для объяснения логики модели был применён метод **SHAP (SHapley Additive exPlanations)** [29], основанный на концепции вектора Шепли из кооперативной теории игр. Он позволяет рассчитать точный маржинальный вклад каждого признака в итоговую вероятность (риск-балл) для любого объекта выборки.

Анализ SHAP-графиков (сводный график, рис.14) по всей тестовой выборке дал следующие результаты:

1. Глобальная важность признаков

По усреднённым абсолютным SHAP-значениям безоговорочным лидером стал признак **V14**, за которым следуют **V4, V12 и V10**.

Примечательно, что этот список во многом пересекается с результатами корреляционного анализа Пирсона, проведённого на этапе разведочного анализа данных. Однако V17, показавший максимальную обратную корреляцию с целевой переменной, уступил лидерство V14. Это объясняется преимуществом градиентного бустинга: алгоритм улавливает нелинейные зависимости и мультиколлинеарные взаимодействия, при которых V14 оказался структурно более информативным узлом ветвления.

2. Направленность влияния признаков на вероятность фрода

Диаграмма рассеяния SHAP (точечный график, рис.15) показала не только силу, но и вектор влияния признаков:

- **Признак V14 (отрицательная зависимость):**

Аномально низкие значения V14 (синие точки) смещены в сторону высоких SHAP-значений — то есть являются сильнейшим триггером мошенничества. Высокие значения V14, напротив, говорят о легитимности операции. Аналогичная картина у **V12 и V10**.

- **Признаки V4 и V11 (положительная зависимость):**

Высокие значения этих признаков (красные точки) вносят существенный положительный вклад в риск-балл, подталкивая модель к блокировке.

Выявленная направленность полностью согласуется с выводами разведочного анализа — алгоритм нашёл реальные закономерности, а не «запомнил

шум». Это математически подтверждает корректность обученной модели.

3. Оценка эффективности конструирования признаков

Особого внимания заслуживает присутствие в топ-15 наиболее важных признаков переменных **Time_{sin}** и **Amount_{log}** — созданных вручную на этапе предобработки.

Тот факт, что ансамбль деревьев присвоил им больший вес, чем многим базовым компонентам PCA (V24, V21, V1 и др.), эмпирически доказывает: конструирование признаков было проведено правильно. Тригонометрическое кодирование времени позволило находить циклические ночные паттерны атак; логарифмирование сумм помогло чётче реагировать на специфические микро-списания, характерные для мошенников, снизив влияние выбросов.

SHAP-анализ обеспечил полную прозрачность модели, подтвердил её адекватность и логичность классификационных правил. Модель готова к интерпретации бизнес-пользователями.

4.2 Анализ экономической эффективности модели

Одних лишь математических метрик (PR-AUC, F1-score) недостаточно для принятия решения о промышленном внедрении системы. Бизнесу важен измеримый финансовый результат. Для этого оптимизированная модель XGBoost была оценена через матрицу затрат, переводящую ошибки классификации в реальные экономические показатели.

Параметры экономической модели:

- **True Positives (TP):**

Верно заблокированная мошенническая транзакция. Экономическая ценность — предотвращённый ущерб, равный фактической сумме операции (Amount).

- **False Negatives (FN):**

Пропущенный фрод. Прямые потери банка — сумма прошедшей мошеннической транзакции.

- **False Positives (FP):**

Ложная тревога (ошибочная блокировка карты честного клиента).
Операционные издержки: затраты на работу службы безопасности и звонок оператора для верификации. Для расчёта принята константа $C_{\text{investigation}} = 10$ у.е. за инцидент.

- **True Negatives (TN):**

Верно одобренная легитимная транзакция. Нулевые издержки — нормальная работа системы.

Итоговая экономическая выгода рассчитывается по формуле (13):

$$\text{Net Benefit} = \sum_{i \in TP} \text{Amount}_i - (FP \cdot C_{\text{investigation}}) \quad (13)$$

Показатель возврата инвестиций (ROI) вычисляется согласно формуле (14):

$$ROI = \left(\frac{\text{Net Benefit}}{FP \cdot C_{\text{investigation}}} \right) \cdot 100\% \quad (14)$$

Эмпирические результаты и обоснование оптимизации порога
Сравним два сценария:

1. **Сценарий «Базовый порог»** ($p = 0,5$):

Модель предотвратила хищения на 8 522,17 у.е. (TP), допустив 9 ложных срабатываний — операционные издержки 90,00 у.е. (FP). Итоговая выгода: **8 432,17 у.е.**, ROI — 9 369,08%.

2. **Сценарий «Оптимизированный порог»** ($p = 0,9634$):

Ужесточение порога привело к небольшому снижению объёма перехваченных операций (предотвращённый ущерб — 8 497,27 у.е., разница ≈ 25 у.е.). Зато количество ложных тревог сократилось втрое: издержки FP упали до 30,00 у.е. В результате *чистая выгода выросла до 8 467,27 у.е.*, а ROI взлетел до 28 224,23%.

Сравнение сценариев наглядно показывает: попытка поймать весь фрод любой ценой (максимизация Recall) математически невыгодна, если затраты

на обработку ложных срабатываний превышают средний чек предотвращённой мошеннической операции. Сознательная «жертва» в 25 у.е. на пропущенном фроде позволила сэкономить 60 у.е. на операционных расходах.

После калибровки порога **ROI увеличился в три раза, достигнув 28 224,23%**. Это означает, что на каждый доллар, потраченный на ручную верификацию ложных срабатываний, система спасает ≈ 282 у.е. клиентских средств.

Вывод:

Разработанная модель не только решает академическую задачу выявления аномалий в условиях экстремального дисбаланса, но и является высоко-рентабельным программным решением. Динамическая оптимизация порога классификации позволяет максимизировать финансовый результат и снизить нагрузку на инфраструктуру безопасности.

Выводы

В ходе работы было проведено комплексное исследование проблемы автоматического выявления мошеннических финансовых транзакций методами машинного обучения. По результатам разведочного анализа данных, математического моделирования и оценки экономической эффективности получены следующие основные выводы:

1. **Выявлена нелинейная топология транзакционных данных и доказана неэффективность линейных алгоритмов.** В условиях экстремального дисбаланса (0,17% мошеннических операций) классы сильно перекрываются. Базовая модель (логистическая регрессия) показала неприемлемо высокий уровень ложных срабатываний ($\text{Precision} \approx 5,7\%$, около 1 500 ложных блокировок), что делает линейные алгоритмы непригодными для промышленного фрод-мониторинга.
2. **Эмпирически подтверждена эффективность конструирования признаков.** Тригонометрическое кодирование временных меток ($\text{Time}_{\sin}$, $\text{Time}_{\cos}$) и логарифмирование сумм транзакций ($\text{Amount}_{\log}$) позволило алгоритмам успешно выявлять циклические паттерны атак и

аномальные микро-списания. Анализ важности признаков подтвердил высокую предиктивную силу созданных переменных.

3. **Обоснован выбор оптимальной стратегии борьбы с дисбалансом классов.** Алгоритмическое взвешивание классов превосходит подход с ресемплированием (SMOTE) по скорости обучения в 2–3 раза без потери качества для XGBoost и CatBoost. Однако алгоритмы с жадным построением по листьям (LightGBM) склонны к коллапсу калибровки вероятностей при экстремальных весах, что требует обязательной регуляризации или перехода к методам на уровне данных.
4. **Определена лучшая предиктивная модель.** Глобальным победителем признан **XGBoost** со взвешиванием классов. Переход к ансамблям деревьев позволил радикально повысить точность классификации (снизив FP с 1 468 до 11) при сохранении высокой полноты обнаружения мошенничества ($\text{Recall} > 81\%$).
5. **Математически доказана необходимость динамической оптимизации порога принятия решений.** Асимметричные штрафы за пропуск фрода смещают распределение вероятностей. Перенос порога с базового $p = 0,5$ до оптимального $p = 0,912$ максимизировал F1-score (рост Precision до 96,39%) и устранил избыточные ложные тревоги.
6. **Решена проблема «чёрного ящика» машинного обучения.** SHAP-анализ обеспечил полную прозрачность модели XGBoost. Выявлены ключевые триггеры мошенничества (аномально низкие значения признаков V14, V12 и V10), что позволяет аналитикам безопасности интерпретировать причины каждой блокировки.
7. **Подтверждена высокая экономическая рентабельность решения.** Экономическая модель на основе матрицы затрат доказала, что осознанное снижение Recall в пользу высокой Precision математически оправдано: оптимизация алгоритма увеличила ROI до 28 224%. Система успешно предотвращает хищения, минимизируя при этом операционные издержки банка.

Таким образом, разработанный программно-алгоритмический комплекс полностью решает поставленную задачу и обладает высокими показателями как математической точности, так и экономической эффективности, что делает его пригодным для внедрения в реальный контур финансовой безопасности.

Заключение

В рамках данной выпускной квалификационной работы было проведено всестороннее теоретическое и практическое исследование задачи автоматического выявления мошеннических финансовых транзакций в условиях цифровизации экономики. Главная цель — разработка, исследование и оптимизация программного модуля антифрод-мониторинга — была достигнута в полном объёме.

Анализ предметной области подтвердил, что классические экспертные системы на жёстких правилах исчерпали свой предиктивный потенциал. Объёмы транзакционных данных растут, тактики злоумышленников меняются, и без адаптивных вероятностных алгоритмов здесь уже не обойтись. При этом ключевым барьером на пути применения машинного обучения остаётся экстремальный дисбаланс классов, требующий специализированных методов.

В практической части был выстроен полный конвейер обработки данных. Особое внимание уделялось конструированию признаков: перевод временных характеристик в тригонометрическое пространство и логарифмирование сумм транзакций существенно повысили качество распознавания аномалий.

Масштабный сравнительный анализ подтвердил недостаточность линейных классификаторов и показал, что семейство алгоритмов градиентного бустинга является индустриальным стандартом для подобных задач. Вместе с тем был выявлен важный нюанс: эффективность метода борьбы с дисбалансом определяется архитектурой конкретного алгоритма. Симметричные деревья (XGBoost) прекрасно работают с алгоритмическим взвешиванием функции потерь, тогда как алгоритмы с жадным построением по листьям (LightGBM) склонны к коллапсу вероятностей при экстремальных весах и лучше сочетаются с методами генерации данных (SMOTE).

Отличительной особенностью данной работы является глубокая интеграция математического моделирования с бизнес-метриками:

- во-первых, модель стала полностью интерпретируемой благодаря SHAP-анализу, что отвечает строгим требованиям банковского сектора;
- во-вторых, алгоритм был откалиброван путём смещения порога принятия решений для максимизации F1-меры;
- в-третьих, оценка качества переведена на язык экономики через матрицу затрат, что наглядно подтвердило высокую рентабельность предложенной системы.

Перспективы дальнейших исследований.

Разработанный модуль имеет хороший потенциал для дальнейшего развития:

1. Интеграция графовых нейронных сетей [10] для обнаружения не только индивидуальных аномалий, но и организованных преступных сетей (схем отмывания денег) на основе топологии транзакционных связей между счетами.
2. Разработка архитектуры потоковой аналитики и внедрение инкрементального обучения для автоматической адаптации к «дрейфу концепции» в режиме реального времени [28].

Результаты работы представляют как научную ценность — раскрывая уязвимости градиентных ансамблей при работе с дисбалансом, так и практическую значимость для обеспечения кибербезопасности финансовых организаций.

Список литературы

- [1] Abdallah Altyeb, Maarof Mohd Aizaini, Zainal Anazida. Fraud detection system: A survey // Journal of Network and Computer Applications. — 2016. — Vol. 68. — P. 90–113.

- [2] A comprehensive survey of data mining-based fraud detection research / Phua Clifton, Lee Vincent, Smith Kate, and Gayler Ross // arXiv preprint arXiv:1009.6119. — 2010.
- [3] Data mining for credit card fraud: A comparative study / Bhattacharyya Siddhartha, Jha Sanjeev, Tharakunnel Kurian, and Westland J Christopher // Decision Support Systems. — 2011. — Vol. 50, no. 3. — P. 602–613.
- [4] Edwards S et al. Credit card fraud detection using extreme gradient boosting // Journal of Risk and Financial Management. — 2018. — Vol. 11, no. 2. — P. 29.
- [5] SMOTE: synthetic minority over-sampling technique / Chawla Nitesh V, Bowyer Kevin W, Hall Lawrence O, and Kegelmeyer W Philip // Journal of Artificial Intelligence Research. — 2002. — Vol. 16. — P. 321–357.
- [6] ADASYN: Adaptive synthetic minority oversampling approach / He Haibo, Bai Yang, Garcia Eduardo A, and Li Shutao // 2008 IEEE International Joint Conference on Neural Networks / IEEE. — 2008. — P. 1322–1328.
- [7] Davis Jesse, Goadrich Mark. The relationship between Precision-Recall and ROC curves // Proceedings of the 23rd International Conference on Machine Learning. — 2006. — P. 233–240.
- [8] Bahnsen Alejandro Correa, Aouada Djamila, Ottersten Björn. Example-dependent cost-sensitive logistic regression for credit card fraud detection // 2014 13th International Conference on Machine Learning and Applications. — 2014. — P. 263–269.
- [9] Pumsirirat Apivadee, Yan Liu. Credit card fraud detection using deep learning based on auto-encoder and restricted Boltzmann machine // International Journal of Advanced Computer Science and Applications. — 2018. — Vol. 9, no. 1. — P. 18–25.
- [10] Enhancing graph neural network-based fraud detectors against camouflaged fraudsters / Dou Yingtong, Liu Zhiwei, Sun Lichao, Deng Yutong, Peng Hao,

- and Yu Philip S // Proceedings of the 29th ACM International Conference on Information & Knowledge Management. — 2020. — P. 315–324.
- [11] Calibrating probability with undersampling for unbalanced classification / Dal Pozzolo Andrea, Caelen Olivier, Johnson Reid A, and Bontempi Gianluca // 2015 IEEE Symposium Series on Computational Intelligence / IEEE. — 2015. — P. 159–166.
 - [12] Dal Pozzolo Andrea. Adaptive Machine Learning for Credit Card Fraud Detection : Ph. D. thesis ; Université Libre de Bruxelles. — 2015.
 - [13] Hastie Trevor, Tibshirani Robert, Friedman Jerome. The elements of statistical learning: data mining, inference, and prediction. — Springer Science & Business Media, 2009.
 - [14] Cortes Corinna, Vapnik Vladimir. Support-vector networks // Machine learning. — 1995. — Vol. 20, no. 3. — P. 273–297.
 - [15] Classification and regression trees / Breiman Leo, Friedman Jerome, Stone Charles J, and Olshen Richard A. — CRC press, 1984.
 - [16] Liu Fei Tony, Ting Kai Ming, Zhou Zhi-Hua. Isolation forest // 2008 Eighth IEEE International Conference on Data Mining / IEEE. — 2008. — P. 413–422.
 - [17] LOF: identifying density-based local outliers / Breunig Markus M, Kriegel Hans-Peter, Ng Raymond T, and Sander Jörg // ACM sigmod record. — 2000. — Vol. 29, no. 2. — P. 93–104.
 - [18] Estimating the support of a high-dimensional distribution / Schölkopf Bernhard, Platt John C, Shawe-Taylor John, Smola Alex J, and Williamson Robert C // Neural computation. — 2001. — Vol. 13, no. 7. — P. 1443–1471.
 - [19] Domingos Pedro. A unified bias-variance decomposition // Proceedings of 17th International Conference on Machine Learning. — 2000. — P. 231–238.

- [20] Breiman Leo. Random forests // Machine learning. — 2001. — Vol. 45, no. 1. — P. 5–32.
- [21] Freund Yoav, Schapire Robert E. A decision-theoretic generalization of on-line learning and an application to boosting // Journal of computer and system sciences. — 1997. — Vol. 55, no. 1. — P. 119–139.
- [22] Friedman Jerome H. Greedy function approximation: a gradient boosting machine // Annals of statistics. — 2001. — P. 1189–1232.
- [23] Chen Tianqi, Guestrin Carlos. XGBoost: A scalable tree boosting system // Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. — 2016. — P. 785–794.
- [24] CatBoost: unbiased boosting with categorical features / Prokhorenkova Liudmila, Gusev Gleb, Vorobev Aleksandr, Dorogush Anna Veronika, and Gulin Andrey // Advances in neural information processing systems. — 2018. — Vol. 31.
- [25] Lightgbm: A highly efficient gradient boosting decision tree / Ke Guolin, Meng Qi, Finley Thomas, Wang Taifeng, Chen Wei, Ma Weidong, and Liu Tie-Yan // Advances in neural information processing systems. — 2017. — Vol. 30.
- [26] Wolpert David H. The lack of a priori distinctions between learning algorithms // Neural computation. — 1996. — Vol. 8, no. 7. — P. 1341–1390.
- [27] He Haibo, Ma Yunqian. Imbalanced learning: foundations, algorithms, and applications. — Wiley-IEEE Press, 2013.
- [28] A survey on concept drift adaptation / Gama Joao, Zliobaite Indre, Bifet Albert, Pechenizkiy Mykola, and Bouchachia Abdelhamid // ACM Computing Surveys (CSUR). — 2014. — Vol. 46, no. 4. — P. 1–37.
- [29] Lundberg Scott M, Lee Su-In. A unified approach to interpreting model predictions // Advances in Neural Information Processing Systems. — 2017. — P. 4765–4774.

Приложение

Датасет, рассмотренный в работе: <https://www.kaggle.com/datasets/mlg-ulb/creditcardfraud>

Скрипт для генерации визуализации данных: <https://github.com/CuteZerg/diploma/blob/main/visualisation.py>

Код с обучением моделей, SHAP-анализом и построением экономической модели: <https://github.com/CuteZerg/diploma/blob/main/diploma.ipynb>




Рис. 1: Распределение классов транзакций (логарифмическая шкала).




Рис. 2: Сравнительный график распределения сумм транзакций в зависимости от класса.




Рис. 3: Матрица корреляций. Выделяются признаки с выраженной негативной корреляцией (красные зоны в строке Class).




Рис. 4: Матрица ошибок и график PR-AUC для логистической регрессии с подходом SMOTE.




Рис. 5: Матрица ошибок и график PR-AUC для логистической регрессии с подходом Class Weights.




Рис. 6: Матрица ошибок и график PR-AUC для LightGBM с подходом Class Weights.




Рис. 7: Матрица ошибок и график PR-AUC для LightGBM с подходом SMOTE.




Рис. 8: Матрица ошибок и график PR-AUC для XGBoost с подходом SMOTE.




Рис. 9: Матрица ошибок и график PR-AUC для XGBoost с подходом Class Weights.




Рис. 10: Матрица ошибок и график PR-AUC для CatBoost с подходом SMOTE.




Рис. 11: Матрица ошибок и график PR-AUC для CatBoost с подходом Class Weights.




Рис. 12: Матрица ошибок и график PR-AUC для XGBoost с подходом Class Weights после настройки гиперпараметров модели.




Рис. 13: Оптимизация вероятностного порога для максимизации F1-score.




Рис. 14: Сводный график SHAP-анализа.




Рис. 15: Точечный график (диаграмма рассеяния) SHAP-анализа.